

ความเห็นของผมต่อการยกระดับ PPO_V2 สู่ Production

ผมอ่านทั้งโค้ด V2, ผลลัพธ์, และรีวิวกี่ 5 ฉบับแล้ว ขอให้ความเห็นตรงไปตรงมาก่อนเริ่มลงมือครับ

1. การวินิจฉัย V2 ของผม

****สิ่งที่ต้องชม:**** Engineering hygiene ของ V9.2 อยู่ในระดับดีมาก (zero-leakage, open-to-open timeline, audit suite 8 ข้อ, friction-matched benchmark) — นี่คือการวางรากฐานที่หายากและ****ห้ามทิ้ง****

****สิ่งที่ตัวเลขบอก:****

| หลักฐาน | การตีความ |

|---|---|

| แพ้ EqW ****ทุก fold**** (-5% ถึง -18% CAGR) | ไม่มี alpha เลย ไม่ใช่แค่ "น้อย" |

| AvgCash 20–79% | Cash trap — reward สอนให้กลัว ไม่ได้สอนให้ชนะ |

| Sharpe mean 0.47, SD 0.59 | ผลไม่เสถียรข้าม regime — เชิงสถิติแทบไม่ต่างจาก noise |

| MaxDD ต่ำกว่า EqW ทุก fold | Agent ทำงาน "ตามที่ถูกสอน" ได้ดี — แปลว่าปัญหาคือ ****objective ผิด ไม่ใช่ PPO เรียนไม่ได้**** |

สรุป: นี่ไม่ใช่ algorithm problem แต่เป็น ****problem formulation problem**** (reward + universe + learning setup)

2. ผมเห็นตรง/ไม่ตรงกับใคร

****เห็นด้วยมากที่สุด: GLM 5.3 และ Claude**** ในเรื่อง realism และวินัยทางสถิติ

- ****Claude ถูกที่สุดเรื่องเป้าหมาย:**** "Sharpe 1.5–2 + ชนะตลาดทุกสภาวะ + long-only ETF" เป็น spec ที่ขัดแย้งกันเอง ผมยืนยันเช่นกัน — แม้แต่ top quant fund ก็ไม่ชนะทุก regime เป้าที่วัดได้จริงคือ ****ชนะ baseline ที่แข็งแกร่งอย่างมีนัยสำคัญทางสถิติบน stitched OOS curve****

- ****GLM จับจุดที่คนอื่นพลาดได้จริง 2 จุด**** ซึ่งผมเห็นว่า****สำคัญมากและควรทำก่อนแทบทุกอย่าง****:

1. ****Correlated rollouts bug**** — ทั้ง 8 workers `reset()` ที่ day 0 เสมอ ทำให้ 8,192 steps/update ซ้ำ regime เดียวกัน 8 เท่า → ต้อง random-start + random episode length

2. ****Reward ขึ้นกับ hidden state**** — `peak\_value`/`prev\_dd` ไม่อยู่ใน observation → value function เดาไม่ได้ → TD variance สูง → policy อนุรักษ์นิยมเกิน นี่คือการอธิบายเชิงกลไกที่ดีที่สุดว่าทำไม agent ถึงซึกแล้ว

****เห็นด้วยกับ Gemini**** เรื่องสถาปัตยกรรม ****Two-Tier (RL Alpha + Deterministic Vol Targeting)**** — เป็นข้อเสนอเดียวที่ implement ได้จริงและ leverage สูงสุด แต่ไม่เชื่อตัวเลขโฆษณา ("Sharpe +30–50%", "DSR พิสูจน์แล้วดัน Sharpe เกิน 1.5") — พวกนี้เป็น best case ไม่ใช่ guarantee

****ไม่เห็นด้วยกับ ChatGPT**** ในช่วงกลาง: Multi-Agent RL (non-stationarity + credit assignment บน ข้อมูลแค่ ~5,000 วัน = สูตร overfit), DreamerV3 (overkill), universe 30–50 ตัวที่เดียว (curse of dimensionality) — ทั้งที่ diagnosis ต้นเรื่องของ ChatGPT ถูกต้องที่สุดประโยคเดียว: "ปัญหาคือ Objective Design ไม่ใช่ PPO"

****จุดที่ผมอยากเพิ่มเอง (ยังไม่มีใครเน้นพอ):****

1. ****Ablation คือหัวใจของคำว่า "alpha จริง"***** — ถ้าระบบเต็ม (RL + Vol Target) ชนะ EqW แต่ EqW+VolTarget เฉยๆ ก็ชนะเท่ากัน แปลว่า RL ไม่มีค่า คุณกำลังเคลมผลของ overlay เป็นผลของ RL ต้องรัน (ก) EqW+VT (ข) Faber trend+VT (ค) ระบบเต็ม แล้ว (ค) ต้องชนะ (ก)(ข) อย่างมีนัยสำคัญเท่านั้น
2. ****Cash ใน sim ได้ 0% แต่ปี 2022–2024 T-bill ให้ 4–5%**** — ใส่ risk-free accrual จะเปลี่ยนทั้ง พฤติกรรม optimal และความยุติธรรมของ backtest
3. ****Data quality****: `yf.download(auto\_adjust=True)` ให้ *adjusted open* ซึ่งไม่ใช่ราคา fill จริง และ yfinance ไม่เหมาะเป็น production data source — ระดับ hedge fund ต้องมี point-in-time store + validation
4. ****นับ trials เข้า Deflated Sharpe**** — คุณอยู่ V9.2 แปลว่าลองมาแล้ว ~9+ รอบ ทุกรอบกีดกันความน่าเชื่อถือของ OOS ต้องเปิด experiment log และ pre-register เกณฑ์ตัดสิน**ก่อน**รันรอบถัดไป

3. สถาปัตยกรรมที่ผมแนะนำ

```mermaid

flowchart TD

A["Data Layer: point-in-time store + validation + cash yield (T-bill)"] --> B["Feature Store: cross-sectional relative strength + regime signals (train-only scaling)"]

B --> C["Tier 1: PPO Alpha Engine - relative weights บน SPY QQQ DIA TLT GLD (fully invested, sum=1)"]

C --> D["Tier 2: Deterministic Risk Overlay - vol targeting + circuit breaker (นอก policy, audit ได้ 100%)"]

D --> E["Tier 3: Execution - no-trade band + open-to-open (คงจาก V2) + slippage logging"]

E --> F["Governance: monitoring, drift detection, kill-switch, paper trading gate"]

```

หลักคิด: ****ให้ RL ทำสิ่งเดียวที่มันถนัด = หา relative alpha**** ส่วน risk management เป็น convex problem ที่คณิตศาสตร์แก้ตรงๆ ได้ ไม่ควรฝากไว้กับ learned policy

4. Roadmap แบบมี Gate (ห้ามข้ามลำดับ)

****Phase 0 — Pre-register (ก่อนเขียนโค้ดบรรทัดเดียว)****

- เขียนเกณฑ์ตัดสินไว้ก่อนเห็นผล: stitched OOS 2016–2026 ต้องชนะ SPY, EqW, 60/40, **EqW+VT, Faber+VT** พร้อม bootstrap CI ที่ไม่ครอบ 0; MaxDD $\leq$ 15%; DSR $\geq$ 0.95 นับ trials ทั้งหมดตั้งแต่ V1

****Phase 1 — แก้ learning problem (ข้อมูลเดิม, ~1–2 สัปดาห์, leverage สูงสุด)****

1. Reward v3: $r = 100 \times (r_{\text{agent}} - r_{\text{EqW}}) - \lambda \cdot \text{turnover}$ — ตัด dd_penalty / cash_drag / vix_drag ทั้งทั้งหมด (reward จะ fully observable)
2. Random-start ต่อ worker + episode length สุ่ม
3. Cash ได้ T-bill yield (point-in-time จาก FRED)
4. Ensemble 3–5 seeds

- ****Gate 1:**** bull folds ต้อง invested $\geq$ 85%, excess $\geq$ 0 อย่างน้อย 3/5 folds

****Phase 2 — Universe + Risk Overlay (~2–4 สัปดาห์)****

- ขยายเป็น ****SPY, QQQ, DIA, TLT, GLD**** (5 ตัวพอ — ไม่ใช่ 30–50)
- Vol targeting: EWMA vol $\rightarrow$ exposure scalar + hysteresis + คัด cost ของ overlay จริง
- Circuit breaker นอก policy (DD > 10% $\rightarrow$ force deleverage)
- ****รัน ablation ครบ 3 ตัว**** ตามข้อ 2 ข้างบน
- ****Gate 2:**** stitched Sharpe $\geq$ 1.2, ชนะ EqW+VT ที่ CI 95%, edge รอดที่ cost 30bps — ****ถ้าไม่ผ่านสองรอบ $\rightarrow$ productionize แบบ rules-based (Faber+VT) ไปก่อน แล้วให้ RL เป็น research track**** นี่ไม่ใช่ความล้มเหลว

****Phase 3 — Representation (มีเงื่อนไข)****

- Frame-stack 10–20 วันก่อน $\rightarrow$ ถ้าช่วยค่อยขึ้น RecurrentPPO — ไม่ใช่ Transformer
- Cross-sectional features (QQQ/SPY ratio, relative momentum, yield curve, VIX term structure)

****Phase 4–5 — Statistical hardening + Production engineering****

- Bootstrap CI, DSR, cost stress 30/50bps, stress periods แยก (2018Q4, 2020Q1, 2022)
- ออกจาก yfinance, feature parity test (replay ย้อนหลังผ่าน live pipeline ต้องได้ features ตรง 100%)
- Paper trading 3–6 เดือน พร้อม gate เขิงตัวเลข $\rightarrow$ เงินจริงขนาดเล็ก $\rightarrow$ scale

5. เรื่องเป้าหมายที่ต้องพูดตรงๆ

Ceiling ที่ realistic ตามโครงสร้าง:

| ระบบ | Sharpe คาดหวัง |

| --- | --- |

| 3 correlated equities + cash (V2) | ~0.8–1.0 ไม่ว่าจะแก้ reward ยังไง |

| + TLT/GLD | ~1.0–1.3 |

| + vol targeting | ~1.2–1.6 backtest (~0.9–1.4 live) |

| + alpha ที่พิสูจน์ผ่าน ablation | >1.5 เป็นไปได้ แต่ต้อง****พิสูจน์ ไม่ใช่ตั้งเป้า**** |

ถ้าต้องการ absolute return สูงด้วย ทางที่ถูกคณิตศาสตร์คือ leverage 1.2–1.5× บน core ที่ Sharpe สูง (พร้อม model financing cost) — ไม่ใช่หวังให้ long-only ชนะทุกอย่างพร้อมกัน

****สรุปสั้นๆ:**** ผมจะเก็บ discipline ของ V2 ไว้ทั้งหมด, แก่ reward + correlated rollouts + cash yield ก่อน (Phase 1 ใช้ข้อมูลเดิม ทดสอบเร็ว), แล้วค่อยขยาย universe + two-tier overlay พร้อม ablation ที่เข้มงวด และ******สิ่งที่กัน overfitting ได้ดีที่สุดไม่ใช่โค้ดที่ฉลาดขึ้น แต่คือ pre-registered gates ที่บอกว่าเมื่อไหร่ควรหยุด******

ถ้าเห็นด้วยกับกรอบนี้ ผมพร้อมเริ่มเขียนโค้ด Phase 1 (Reward v3 + random-start + cash yield + baselines EqW-VT/Faber-VT) ให้เป็นขั้นแรกเลยครับ — ต้องการให้เริ่มจากส่วนไหนก่อนดี?

