การเปรียบเทียบรูปแบบการแบ่งข้อมูลตามเวลาสำหรับการจัดสรรพอร์ตลงทุนด้วย PPO

A Comparison of Temporal Data-Splitting Schemes for PPO-Based Portfolio Allocation

อองรักษ์ วณิชชานัย[1], ณภัทร วานิชวัตถากร[2],

ผศ.ดร. นนท์ คนึงสุขเกษม[3] และ ผศ.ดร. อนันตพัฒน์ อนันตชัย[4]

คณะเทคโนโลยีสารสนเทศ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

เลขที่ 1 ซอยฉลองกรุง 1 แขวงลาดกระบัง เขตลาดกระบัง กรุงเทพฯ 10520

บทคัดย่อ

งานวิจัยนี้ศึกษาเปรียบเทียบรูปแบบการแบ่งข้อมูลตามเวลา 3 สถาปัตยกรรม ได้แก่ Single Holdout, Expanding Window และ Sliding Window สำหรับการจัดสรรพอร์ตโฟลิโอด้วย Proximal Policy Optimization (PPO) บนสินทรัพย์ SPY, QQQ, DIA, TLT, GLD และเงินสด ภายใต้ระบบควบคุมความเสี่ยงแบบสองชั้น (Volatility Targeting และ Soft Drawdown Dampener) การประเมินผลแบ่งเป็น 3 ส่วน ได้แก่ การทดสอบย้อนหลังบนช่วงนอกตัวอย่างร่วมกัน (Common OOS: 2024–2026), การวิเคราะห์ Walk-Forward 5 Folds (2016–2026) และการทดสอบอนุมานสด 5 วันทำการบนบัญชีจำลอง Webull OpenAPI Sandbox ผลการทดลองเดิมรายงาน Sharpe Ratio บนช่วง Common OOS เท่ากับ 1.99, 2.01 และ 2.44 สำหรับ Single Holdout, Expanding Window และ Sliding Window ตามลำดับ โดย Sliding Window แสดงความทนทานต่อสภาวะวิกฤติได้ดีที่สุดในช่วงปี 2022–2023 ขณะที่การทดสอบสดพบว่าทุกโมเดลมีมูลค่าบัญชีเพิ่มขึ้นประมาณ 0.85% แต่เกิดสภาวะถือครองใกล้เคียง Equal-Weight (~20% ต่อสินทรัพย์) และไม่มีการปรับพอร์ตหลังวันแรก การตรวจสอบระบบเชิงลึกเปิดเผยข้อบกพร่องวิกฤติ 2 ประการ ได้แก่ (1) การนำ Z-Score ของอัตราดอกเบี้ย FEDFUNDS ไปคำนวณผลตอบแทนเงินสดในระบบบัญชี และ (2) กลไก EvalCallback บันทึก Checkpoint ที่ 4,000 timesteps ก่อนการอัปเดตนโยบายรอบแรก (_n_updates = 0) ส่งผลให้โมเดลในการทดสอบสดกลายสภาพเป็นนโยบายสุ่มเริ่มต้น งานวิจัยนี้จึงชี้ชัดว่าการตรวจสอบความถูกต้องของระบบบัญชีและสถาปัตยกรรมการฝึกฝน มีความจำเป็นอย่างยิ่งก่อนการตีความตัวชี้วัดทางการเงิน

คำสำคัญ: การเรียนรู้แบบเสริมกำลัง, PPO, การจัดสรรพอร์ตลงทุน, การแบ่งข้อมูลตามเวลา, การทดสอบย้อนหลัง, การทดสอบเดินหน้า

---

* Author's Email: 67070297@kmitl.ac.th, 67070226@kmitl.ac.th

[1, 2] นักศึกษาปริญญาตรี สาขาวิชาเทคโนโลยีปัญญาประดิษฐ์ คณะเทคโนโลยีสารสนเทศ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

[3, 4] ผู้ช่วยศาสตราจารย์ คณะเทคโนโลยีสารสนเทศ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

1. บทนำ

1.1 ที่มาและความสำคัญ

การประยุกต์ใช้การเรียนรู้แบบเสริมกำลังเชิงลึก (Deep Reinforcement Learning: DRL) [1] ในการจัดสรรพอร์ตการลงทุนได้รับความสนใจอย่างกว้างขวาง เนื่องจากตัวแทน (Agent) สามารถเรียนรู้นโยบายแบบไดนามิกตามสภาวะตลาดที่เปลี่ยนแปลงไป อย่างไรก็ดี อุปสรรคพื้นฐานของการนำ DRL มาใช้กับข้อมูลอนุกรมเวลาทางการเงินคือปัญหา Non-Stationarity และ Data Snooping Bias [2] ข้อมูลทางการเงินมีโครงสร้างทางสถิติที่แปรผันตามเวลา (Regime Shifts) ทำให้แบบจำลองที่ได้รับการฝึกฝนบนช่วงเวลาใดเวลาหนึ่งมักเกิดสภาวะ Overfitting ต่อสภาวะตลาดในอดีตและล้มเหลวเมื่อนำไปปรับใช้จริง

ในการประเมินประสิทธิภาพของอัลกอริทึม เช่น Proximal Policy Optimization (PPO) [3] ระเบียบวิธีการแบ่งชุดข้อมูลตามเวลา (Temporal Data-Splitting) ถือเป็นหัวใจสำคัญที่มีผลต่อทั้งเสถียรภาพและระดับความรู้ที่โมเดลได้รับ งานวิจัยส่วนใหญ่มักพึ่งพาการแบ่งข้อมูลแบบครั้งเดียว (Single Holdout) ซึ่งสุ่มเสี่ยงต่อการเกิดอคติจากการเลือกช่วงเวลา (Selection Bias) ในขณะที่การประเมินแบบเลื่อนไปข้างหน้า (Walk-Forward Validation) ไม่ว่าจะเป็นแบบหน้าต่างสะสม (Expanding Window) หรือหน้าต่างขนาดคงที่ (Sliding Window) ช่วยให้สามารถทดสอบความทนทานของโมเดลข้ามวัฏจักรเศรษฐกิจได้สมจริงยิ่งขึ้น [4]

1.2 งานวิจัยนี้ตั้งคำถามวิจัยหลัก 3 ข้อ (RQs):

- RQ1: เมื่อควบคุมช่วงเวลาทดสอบนอกตัวอย่างร่วมกัน (Common OOS: 2024–2026) ระเบียบวิธี Single Holdout, Expanding Window และ Sliding Window ให้ผลลัพธ์ความเสี่ยงและผลตอบแทนแตกต่างกันอย่างไร?
- RQ2: ความสามารถในการปรับตัวข้ามสภาวะตลาด (Cross-Regime Robustness) ของ Expanding Window และ Sliding Window แปรผันอย่างไรตลอด 5 Folds (2016–2026)?
- RQ3: พฤติกรรมการจัดสรรสินทรัพย์ในการทดสอบอนุมานจริง (Forward Test) มีความสอดคล้องกับผลการจำลองในอดีต (Backtest) หรือไม่ และหลักฐานเชิงประจักษ์เพียงพอที่จะสนับสนุนสมมติฐานดังกล่าวหรือไม่?

1.3 คุณูปการของงานวิจัย (Research Contributions):

1. การเปรียบเทียบสถาปัตยกรรมแบ่งข้อมูลภายใต้กรอบการทดลองเดียวกัน: ดำเนินการทดลองเปรียบเทียบทั้งสามวิธีภายใต้ Feature Engineering, การจำลองค่าธรรมเนียมธุรกรรม 15 bps, และกลไก Two-Tier Volatility Targeting เดียวกัน

2. การผสานระบบ Live Execution กับ Broker Sandbox จริง: พัฒนาระบบส่งคำสั่งซื้อขายอัตโนมัติเชื่อมต่อไปยัง Webull OpenAPI Sandbox พร้อมกลไกบันทึกสถานะความเสี่ยงสะสมข้ามวัน (state_manager.py)

3. การตรวจสอบเชิงนิติวิทยาศาสตร์ของระบบ (Forensic System Audit): เปิดเผยข้อผิดพลาดทางวิศวกรรมที่มักถูกมองข้าม ได้แก่ ข้อผิดพลาดในการปรับมาตรฐานอัตราดอกเบี้ยบัญชีเงินสด และข้อจำกัดของ Checkpoint Selection ใน Stable-Baselines3 [5] ซึ่งเป็นบทเรียนสำคัญสำหรับชุมชนนักวิจัย Financial ML

2. การสร้างแบบจำลองทางคณิตศาสตร์และกรอบการทำงาน (Problem Formulation)

กระบวนการจัดสรรสินทรัพย์ถูกกำหนดให้อยู่ในรูปแบบ Markov Decision Process (MDP) แบบเวลาไม่ต่อเนื่อง:

2.1 ปริภูมิสถานะ (State Space, $\mathcal{S}$)

สถานะ ณ เวลา t คือเวกเตอร์ $\mathbf{s}_t \in \mathbb{R}^{93}$ ประกอบด้วย 3 องค์ประกอบหลัก:

$$\mathbf{s}_t = \left[\mathbf{z}_{t,1}, \mathbf{z}_{t,2}, \ldots, \mathbf{z}_{t,K}, \mathbf{w}_t^{\text{obs}}, s_t^{\text{risk}}, \frac{\sigma_t^{\text{realized}}}{\sigma^{\text{target, daily}}} \right] \in \mathbb{R}^{93}$$

- $K = 5$ คือจำนวนสินทรัพย์เสี่ยง (SPY, QQQ, DIA, TLT, GLD)
- $\mathbf{z}_{t,k} \in \mathbb{R}^{17}$ คือเวกเตอร์คุณลักษณะที่ผ่านการปรับมาตรฐานแล้วของสินทรัพย์ k ($5 \times 17 = 85$ มิติ)
- $\mathbf{w}_t^{\text{obs}} \in \mathbb{R}^6$ คือน้ำหนักการถือครองสินทรัพย์จริงก่อนเปิดตลาดวันทำการถัดไป (รวมสัดส่วนเงินสด $w_{t,0}$)
- $s_t^{\text{risk}} \in \mathbb{R}$ คือขนาดของ Risk Exposure Scalar ล่าสุด
- $\frac{\sigma_t^{\text{realized}}}{\sigma^{\text{target, daily}}} \in \mathbb{R}$ คืออัตราส่วนความผันผวนจริงต่อเป้าหมาย

2.2 การปรับมาตรฐานคุณลักษณะเฉพาะช่วงฝึกฝน (Train-Only Z-Score Normalization)

เพื่อป้องกันการรั่วไหลของข้อมูล (Data Leakage) สถิติเฉลี่ยและส่วนเบี่ยงเบนมาตรฐานต้องคำนวณจากชุด Train ($\mathcal{T}_{\text{train}}$) ของแต่ละ Fold เท่านั้น:

$$z_{t,j} = \text{clip}\left(\frac{x_{t,j} - \mu_j^{\text{train}}}{\sigma_j^{\text{train}} + \epsilon_{\text{norm}}}, -\sigma_{\text{clip}}, \sigma_{\text{clip}}\right)$$

- $x_{t,j}$: ค่าดิบของคุณลักษณะ $j \in \{1, \dots, 17\}$ ณ เวลา t
- $\mu_j^{\text{train}} = \frac{1}{|\mathcal{T}_{\text{train}}|} \sum_{t \in \mathcal{T}_{\text{train}}} x_{t,j}$: ค่าเฉลี่ยเลขคณิตจากช่วงฝึกฝน
- $\sigma_j^{\text{train}} = \sqrt{\frac{1}{|\mathcal{T}_{\text{train}}|-1} \sum_{t \in \mathcal{T}_{\text{train}}} \left(x_{t,j} - \mu_j^{\text{train}}\right)^2}$: ส่วนเบี่ยงเบนมาตรฐานจากช่วงฝึกฝน
- $\epsilon_{\text{norm}} = 10^{-6}$: ค่าคงที่ป้องกันการหารด้วยศูนย์
- $\sigma_{\text{clip}} = 5.0$: ค่าขอบเขตตัดทอนความผิดปกติ (Outlier Clipping)

2.3 การแปลงการกระทำสู่สัดส่วนการลงทุน (Softmax Action Mapping)

เครือข่ายนโยบาย (Actor Network) ส่งออกเวกเตอร์การกระทำต่อเนื่อง $\mathbf{a}_t \in [-3.0, 3.0]^K$ ซึ่งถูกแปลงเป็นสัดส่วนสัมพัทธ์ระหว่างสินทรัพย์เสี่ยงด้วยฟังก์ชัน Softmax:

$$p_{t,i} = \frac{\exp(a_{t,i})}{\sum_{k=1}^{K} \exp(a_{t,k})}, \quad \forall i \in \{1, \dots, K\}$$

โดยมีเงื่อนไขบังคับ $\sum_{i=1}^{K} p_{t,i} = 1.0$ และ $p_{t,i} \geq 0$

2.4 กลไกควบคุมความเสี่ยงแบบสองชั้น (Two-Tier Volatility Targeting & Soft Dampener)

ระบบประมาณการความผันผวนของพอร์ตโฟลิโอด้วยแบบจำลอง EWMA ($\lambda_{\text{ewma}} = 0.94$):

$$\sigma_t^2 = \lambda_{\text{ewma}} \sigma_{t-1}^2 + (1 - \lambda_{\text{ewma}})(r_{t-1}^{\text{port}})^2, \quad \sigma_t^{\text{realized}} = \sqrt{\max(\sigma_t^2, 10^{-8})}$$

- σ_t^2: ค่าความแปรปรวนรายวันของพอร์ตโฟลิโอ
- r_{t-1}^{port}: ผลตอบแทนรวมของพอร์ตในก้าวก่อนหน้า

คำนวณตัวคูณ Exposure ร่วมกับกลไกหน่วงการขาดทุนสะสม (Soft Drawdown Dampener):

$$s_t^{\text{raw}} = \left(\frac{\sigma^{\text{target, daily}}}{\sigma_t^{\text{realized}}}\right) \times \psi(DD_t)$$

$$\psi(DD_t) = 1.0 - \min(0.50, \max(0, DD_t - 0.15) \times 2.0)$$

$$DD_t = \max\left(0,\ 1.0 - \frac{V_t}{V_t^{\text{peak}}}\right)$$

- $\sigma^{\text{target, daily}} = \frac{0.10}{\sqrt{252}} \approx 0.0063$: เป้าหมายความผันผวนรายวัน (อิงจาก 10% ต่อปี)
- V_t, V_t^{peak}: มูลค่าสุทธิปัจจุบันและมูลค่าสูงสุดในอดีตของพอร์ต
- $\psi(DD_t)$: บทลงโทษปรับลด Exposure นุ่มนวลเมื่อ $DD_t > 15\%$ (ลดลงได้สูงสุด 50%)

นำสเกลาร์ดิบมาจำกัดกรอบ Long-Only $[0.20,1.00]$ และกรองด้วย Hysteresis Band ($\delta_{\text{hyst}} = 0.05$) เพื่อลดการหมุนเวียนพอร์ตที่ไม่จำเป็น:

$$s_t = \begin{cases} s_{t-1} & \text{if } |\text{clip}(s_t^{\text{raw}}, 0.20, 1.00) - s_{t-1}| < 0.05 \\ \text{clip}(s_t^{\text{raw}}, 0.20, 1.00) & \text{otherwise} \end{cases}$$

น้ำหนักเป้าหมายสุดท้ายของสินทรัพย์เสี่ยงและเงินสด ($w_{t,0}$) กำหนดโดย:

$$w_{t,i} = s_t \cdot p_{t,i} \quad (i = 1, \dots, K), \qquad w_{t,0} = \max\left(0, 1.0 - \sum_{i=1}^{K} w_{t,i}\right)$$

2.5 การควบคุม Turnover และการประเมินมูลค่าพอร์ต (Financial Accounting)

คำนวณอัตราการหมุนเวียนของสินทรัพย์เสี่ยงเทียบกับพอร์ตที่เกิด Drift ข้ามวัน:

$$\tau_t^{\text{cand}} = \sum_{i=1}^{K} \left| w_{t,i} - w_{t-1,i}^{\text{drifted}} \right|$$

$$\tau_t = \begin{cases} 0.0 & \text{if } \tau_t^{\text{cand}} < 0.01 \quad (\text{No-Trade Band 1\%}) \\ \tau_t^{\text{cand}} & \text{otherwise} \end{cases}$$

เมื่อ $\tau_t \geq 0.01$ พอร์ตโฟลิโอจะถูกหักต้นทุนธุรกรรม $C_t = V_t \cdot c_{\text{bps}} \cdot \tau_t$ โดย $c_{\text{bps}} = 0.0015$ (15 bps) และประเมินมูลค่าข้ามวันแบบ Open-to-Open:

$$V_{t+1} = (V_t - C_t)\left[w_{t,0}(1 + y_t^{\text{cash}}) + \sum_{i=1}^{K} w_{t,i} \left(\frac{O_{t+2,i}}{O_{t+1,i}} \right) \right]$$

- $O_{t+1,i}, O_{t+2,i}$: ราคาเปิด ณ วันส่งคำสั่งและวันประเมินมูลค่า
- $y_t^{\text{cash}} = (1 + \text{FF}_t)^{1/252} - 1$: ผลตอบแทนดอกเบี้ยเงินสดรายวัน

2.6 ฟังก์ชันรางวัล (Reward Formulation)

ฟังก์ชันรางวัลถูกออกแบบให้มุ่งเน้นการสร้างผลตอบแทนส่วนเกิน (Excess Return) เหนือเกณฑ์มาตรฐาน Equal-Weight พร้อมหักบทลงโทษ Turnover:

$$R_t = 100 \times \left(\frac{V_{t+1} - V_t}{V_t} - r_t^{\text{EqW}} \right) - 100 \times \lambda_{\text{turn}} \cdot \tau_t$$

โดย $r_t^{\text{EqW}} = \frac{1}{K} \sum_{i=1}^{K} \left(\frac{O_{t+2,i}}{O_{t+1,i}} - 1.0 \right)$ และ $\lambda_{\text{turn}} = 0.0015$

3. ข้อมูลและระเบียบวิธีแบ่งข้อมูลตามเวลา (Data Pipeline & Splitting Schemes)

ชุดข้อมูลครอบคลุมช่วงเวลา 15 มิถุนายน 2001 ถึง 28 กรกฎาคม 2026 (รวม 6,321 วันทำการที่ข้อมูลสมบูรณ์ 100%) สินทรัพย์ GLD ในช่วงก่อนจัดตั้งถูกสังเคราะห์ย้อนหลังด้วย COMEX Gold Futures (GC=F) หักค่าธรรมเนียมกองทุน 0.40% ต่อปี และ TLT ถูกสังเคราะห์ด้วย Vanguard Long-Term Treasury Fund (VUSTX)

3.1 คุณลักษณะ 17 ตัวแปรประกอบด้วย:

1. Technicals (9): RSI 14-day, Relative RSI, MACD Histogram Pct, EMA 12/26, EMA 50/200, Price to EMA200, StochRSI %K, Momentum 20-day, Momentum 63-day

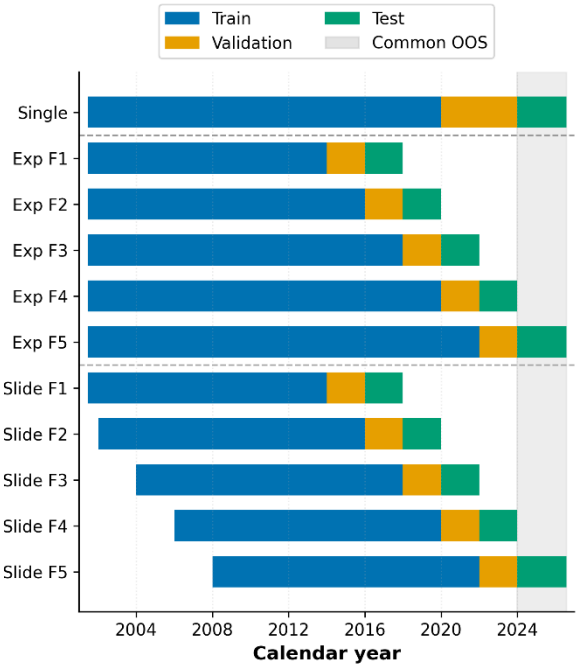
2. Cross-Sectional (3): อัตราส่วนราคา QQQ/SPY, SPY/TLT, และอันดับเปอร์เซ็นไทล์ของโมเมนตัม 63 วัน (Cross-Sectional Momentum Rank)

3. Macro Regimes (5): $\ln(\text{VIX})$, ความชันเส้นอัตราผลตอบแทนพันธบัตร (TNX — IRX), ผลตอบแทนรายวันของทองคำ (GC=F), ผลตอบแทนรายวันของน้ำมันดิบ (CL=F), และอัตราดอกเบี้ยนโยบายสหรัฐฯ FEDFUNDS (หน่วงเวลา 35 วันตามรอบเผยแพร่)

ตารางที่ 1 โครงสร้างการแบ่งชุดข้อมูลตามเวลา (Data-Splitting Timeline)]

Scheme	Fold	Training	Validation	Test (OOS)
Single Holdout	1	2001-06-15 – 2019-12-31 (4,668 วัน)	2020-01-02 – 2023-12-29 (1,006 วัน)	2024-01-02 – 2026-07-28 (647 วัน)
Expanding Window	1	2001-06-15 – 2013-12-31 (3,158 วัน)	2014-01-02 – 2015-12-31 (504 วัน)	2016-01-04 – 2017-12-29 (503 วัน)
	2	2001-06-15 – 2015-12-31 (3,662 วัน)	2016-01-04 – 2017-12-29 (503 วัน)	2018-01-02 – 2019-12-31 (503 วัน)
	3	2001-06-15 – 2017-12-29 (4,165 วัน)	2018-01-02 – 2019-12-31 (503 วัน)	2020-01-02 – 2021-12-31 (505 วัน)

Scheme	Fold	Training	Validation	Test (OOS)
Expanding Window (ต่อ)	4	2001-06-15 – 2019-12-31 (4,668 วัน)	2020-01-02 – 2021-12-31 (505 วัน)	2022-01-03 – 2023-12-29 (501 วัน)
	5	2001-06-15 – 2021-12-31 (5,173 วัน)	2022-01-03 – 2023-12-29 (501 วัน)	2024-01-02 – 2026-07-28 (647 วัน)
Sliding Window	1	2001-06-15 – 2013-12-31 (3,158 วัน)	2014-01-02 – 2015-12-31 (504 วัน)	2016-01-04 – 2017-12-29 (503 วัน)
	2	2002-01-02 – 2015-12-31 (3,527 วัน)	2016-01-04 – 2017-12-29 (503 วัน)	2018-01-02 – 2019-12-31 (503 วัน)
	3	2004-01-02 – 2017-12-29 (3,526 วัน)	2018-01-02 – 2019-12-31 (503 วัน)	2020-01-02 – 2021-12-31 (505 วัน)
	4	2006-01-03 – 2019-12-31 (3,525 วัน)	2020-01-02 – 2021-12-31 (505 วัน)	2022-01-03 – 2023-12-29 (501 วัน)
	5	2008-01-02 – 2021-12-31 (3,526 วัน)	2022-01-03 – 2023-12-29 (501 วัน)	2024-01-02 – 2026-07-28 (647 วัน)

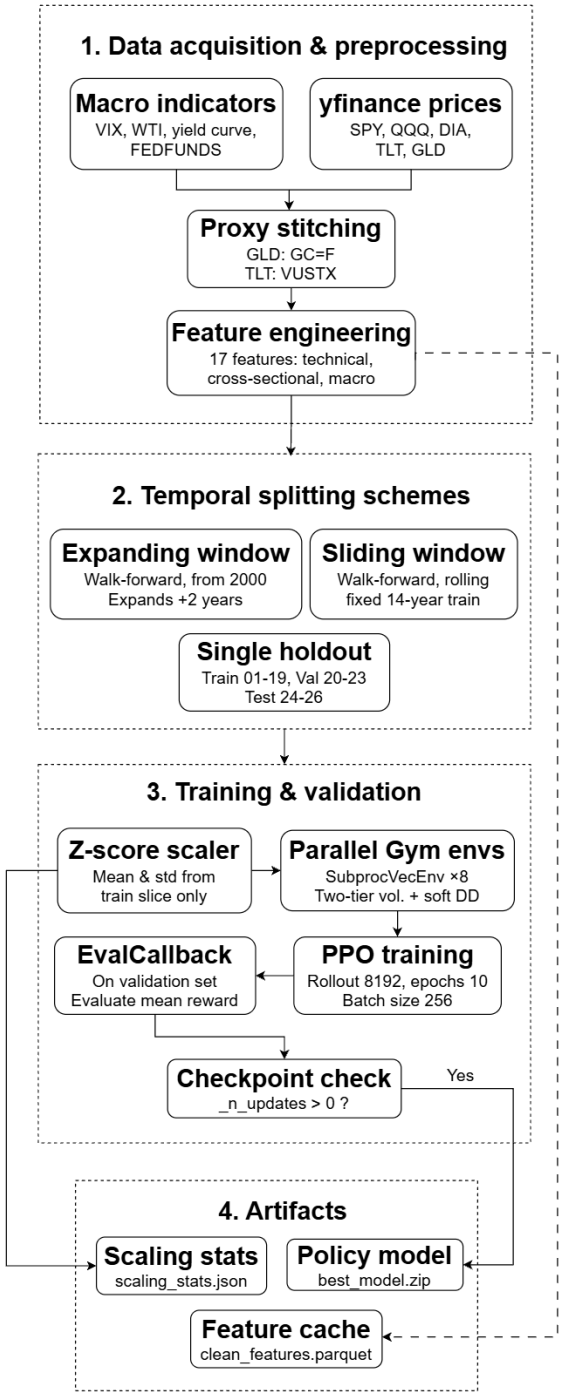


รูปที่ 1: แผนภาพการแบ่งชุดข้อมูลตามเวลาและช่วงทดสอบร่วม

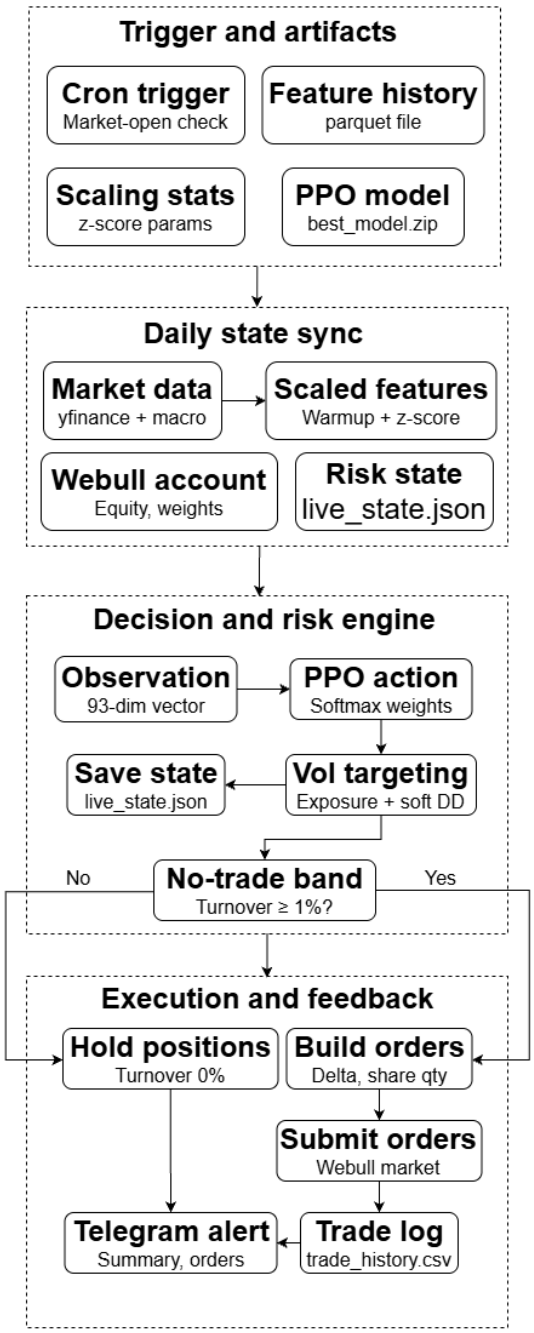
หมายเหตุ: ชี้ให้เห็นว่าช่วง Common OOS ปี 2024–2026 เป็นช่วงทดสอบที่ตรงกันทุกประการของ Single Holdout, Expanding Fold 5, และ Sliding Fold 5

4. สถาปัตยกรรมระบบการทดลองสองส่วน (Dual-Phase System Architecture)

เพื่อให้การทดลองสอดคล้องกับระเบียบวิธีวิจัยระดับสถาบัน โครงสร้างระบบถูกแยกออกเป็น 2 ระบบย่อยอย่างชัดเจน โดยสื่อสารกันผ่าน Immutable Artifact Interface:



รูปที่ 2: Offline Pipeline



รูปที่ 3: *Online Engine*

ระบบ **Offline Pipeline (รูปที่ 2)** ทำหน้าที่สร้างแบบจำลอง PPO และสกัดคุณลักษณะทางสถิติ เมื่อสิ้นสุดการฝึกฝน Artifacts ทั้ง 3 ไฟล์จะถูกส่งมอบไปยัง **Online Engine (รูปที่ 3)** อย่างรัดกุม:

1. best_model.zip: น้ำหนักนโยบาย Neural Network สำหรับทำ Deterministic Inference

2. scaling_stats.json: ค่า $\mu_j^{\text{train}}, \sigma_j^{\text{train}}$ สำหรับปรับสเกลข้อมูลสดในวันทำการนั้น ๆ ให้ตรงกับสเกลที่โมเดลเรียนรู้

3. clean_features_full_history.parquet: ฐานข้อมูลประวัติราคาเพื่อใช้คำนวณ Warmup Indicators (เช่น 200-day SMA)

สำหรับการดำเนินงานในฝั่ง Online เพื่อรองรับกระบวนการรันสดข้ามวัน ระบบจะอาศัยสคริปต์ state_manager.py สำหรับทำหน้าที่ในการบันทึกสถานะ live_state_<scheme>_ppo.json ทั้งนี้เพื่อรักษาค่าความแปรปรวนสะสม (σ_t^2) และยอดสูงสุด (V_t^{peak}) ต่อเนื่อง ก่อนส่งคำสั่งไปยัง Webull OpenAPI ผ่าน (Sandbox Environment)

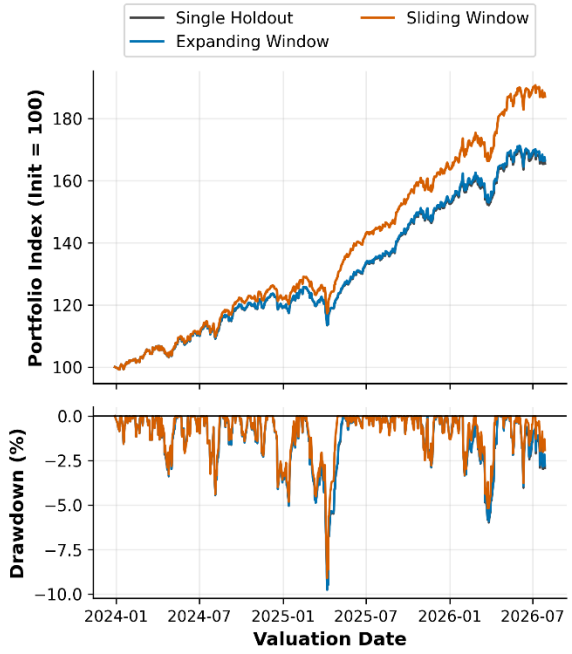
5. ผลการประเมินเชิงประจักษ์ (Empirical Results)

5.1 การประเมินผลบนช่วงทดสอบร่วมกัน (Common OOS: 2024–2026)

ผลการดำเนินงานบนช่วงเวลานอกตัวอย่างร่วมกัน (2 มกราคม 2024 ถึง 28 กรกฎาคม 2026, 647 วันทำการ) สรุปได้ดังตารางที่ 2:

ตารางที่ 2: ผลการดำเนินงานเปรียบเทียบบนช่วงทดสอบนอกตัวอย่างร่วมกัน (Common OOS)

ตัวชี้วัด	Single Holdout	Expanding (F5)	Sliding (F5)	EqW-VT	EqW-Raw
CAGR (%)	21.93%	22.22%	27.91%	12.24%	16.41%
Sharpe Ratio	1.99	2.01	2.44	1.48	1.34
MDD (%)	-9.77%	-9.77%	-9.11%	-7.03%	-11.57%
Sortino Ratio	1.86	1.87	2.26	-	-
Win Rate (%)	58.45%	58.76%	60.93%	-	-
Profit Factor	1.40	1.41	1.52	-	-
Daily Exp. (%)	+0.0008 %	+0.0008 %	+0.0010 %	-	-
Cash Ratio (%)	7.85%	7.83%	7.89%	-	-



รูปที่ 4 : มูลค่าพอร์ตและ Drawdown (Common OOS)

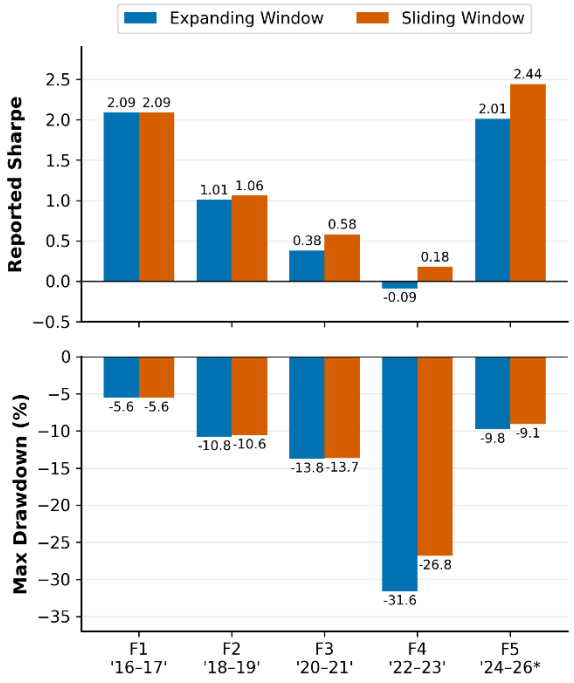
จากการวิเคราะห์รูปที่ 4 พบว่า Sliding Window สามารถสร้าง Pure Alpha เหนือกว่า Equal-Weight Volatility Targeting ได้ถึง +15.68% CAGR ขณะที่ Single Holdout และ Expanding Window มีเส้นการเติบโตของมูลค่าพอร์ตที่แนบชิดกันตลอดช่วงเวลา โดยให้ค่า Sharpe Ratio ใกล้เคียงกันที่ 1.99 และ 2.01 ตามลำดับ

5.2 การวิเคราะห์ความแปรผันข้ามสภาวะตลาด (Cross-Fold Walk-Forward Robustness)

ตารางที่ 3 แสดงผลการทดสอบย้อนหลังแบบแยกราย Fold ระหว่าง Expanding Window และ Sliding Window:

ตารางที่ 3: การเปรียบเทียบผลการทดสอบราย Fold (Folds 1–5: 2016–2026)

Fold	ช่วงเวลา Test	Exp. Sharpe	Slide Sharpe	Exp. MDD (%)	Slide MDD (%)	สภาวะตลาดเด่น
1	2016 – 2017	2.09	2.09	-5.56	-5.56	Low-vol Bull
2	2018 – 2019	1.01	1.06	-10.80	-10.59	Trade War
3	2020 – 2021	0.38	0.58	-13.76	-13.67	COVID-19
4	2022 – 2023	-0.09	0.18	-31.60	-26.83	Rate Hikes
5	2024 – 2026	2.01	2.44	-9.77	-9.11	AI Bull Run
เฉลี่ย	-	1.08	1.27	-14.30	-13.15	-
Stitched	2016 – 2026	1.01	1.22	-32.31	-27.52	-



รูปที่ 5: Sharpe Ratio และ Max Drawdown ราย Fold

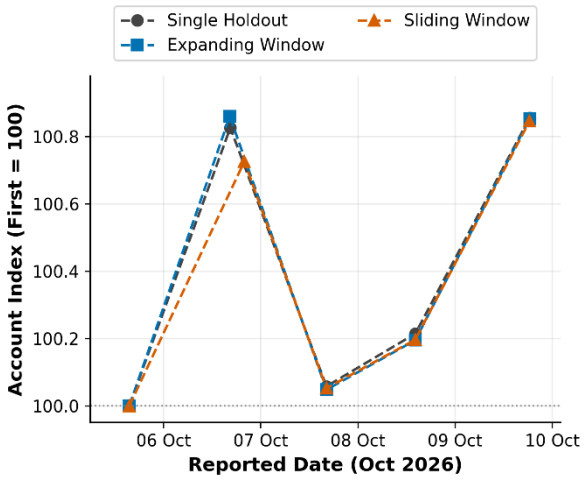
Fold 4 เป็นช่วงเวลาที่ท้าทายที่สุดของพอร์ต Multi-Asset เนื่องจากทั้งตลาดตราสารทุน (SPY, QQQ) และพันธบัตรรัฐบาล (TLT) ปรับตัวลดลงพร้อมกันจากเงินเฟ้อและการขึ้นอัตราดอกเบี้ยอย่างรวดเร็วของธนาคารกลางสหรัฐฯ ในจุดนี้ **Sliding Window แสดงข้อได้เปรียบที่เหนือกว่าอย่างชัดเจน** โดยสามารถประคอง Sharpe Ratio ให้เป็นบวกได้ที่ 0.18 และจำกัด Drawdown ไว้ที่ -26.83% ขณะที่ Expanding Window มีค่า Sharpe ติดลบ (-0.09) และ Drawdown ถลำลึกถึง -31.60% การตัดข้อมูลเก่าที่ตกยุค (ช่วงปี 2000–2005) ออกไปของ Sliding Window ช่วยให้นโยบายปรับตัวเข้ากับ Regime ดอกเบี้ยสูงได้เร็วกว่าโมเดลที่แบกประวัติข้อมูลยาวนานเกินไป

6. ผลการทดสอบอนุมานสดหน้างาน (Forward Test & Live Execution)

การทดสอบเดินหน้าดำเนินการระหว่างวันที่ 5 ถึง 9 ตุลาคม 2026 ผ่าน Webull OpenAPI Sandbox สรุปผลการเปลี่ยนแปลงสถานะบัญชีและคำสั่งซื้อขายได้ดังตารางที่ 4:

ตารางที่ 4: สรุปผลการดำเนินงานรายวันในการทดสอบเดินหน้า (5–9 ตุลาคม 2026)

วันที่ประเมิน	มิติการประเมิน	Single Holdout PPO	Expanding Window PPO	Sliding Window PPO
05/10/2026	Net Liquidation	$999,992.29	$999,983.04	$1,000,000.00
	คำสั่งซื้อขาย (Day 1)	Buy 5 ETFs (~20% เท่ากัน)	Buy 5 ETFs (~20% เท่ากัน)	Buy 5 ETFs (~20% เท่ากัน)
	Turnover	100.00%	100.00%	100.00%
06/10/2026	Net Liquidation	$1,008,249.25	+$6,092.57	$1,007,253.94
	Day P/L	+$5,731.62	+$6,092.57	+$4,803.61
	Order Status	No-Trade (Turnover 0.0%)	No-Trade (Turnover 0.0%)	No-Trade (Turnover 0.0%)
07/10/2026	Net Liquidation	$1,000,567.13	$1,000,457.19	$1,000,519.00
	Day P/L	-$6,821.72	-$6,879.32	-$6,784.78
08/10/2026	Net Liquidation	$1,002,132.95	$1,001,929.33	$1,001,961.33
	Day P/L	+$819.20	+$703.55	+$765.83
09/10/2026	Net Liquidation สิ้นสุด	$1,008,544.74	$1,008,510.25	$1,008,458.66
	มูลค่ากำไรสะสม 5 วัน	+$8,552.45	+$8,527.21	+$8,458.66
	อัตราผลตอบแทนรวม	+0.8553%	+0.8527%	**+0.8459%**



รูปที่ 6: *ดัชนีมูลค่าบัญชีในการทดสอบสด (Forward Test)*

6.1 การค้นพบพฤติกรรมความเฉื่อยชาของนโยบาย (Policy Degeneracy & Inertia):

1. **การลู่เข้าสู่ Equal Weight ตั้งแต่วันแรก:** ในวันที่ 5 ตุลาคม ทุกโมเดลส่งคำสั่งซื้อสินทรัพย์ทั้ง 5 รายการในสัดส่วนประมาณ 20% เท่ากันเกือบสมบูรณ์ (เช่น Single Holdout สั่งซื้อ SPY 19.9%, QQQ 20.1%, DIA 20.0%, TLT 20.1%, GLD 19.9%) และเหลือเงินสดเพียง ~0.1%

2. **Turnover เป็น 0.00% ตลอดวันที่ 2 ถึง 5:** หลังจากวันแรก ไม่มีโมเดลใดส่งคำสั่งซื้อขายใหม่เลย (No-Trade) เนื่องจาก Action ที่โมเดลทำนายในแต่ละวันมีการเปลี่ยนแปลงน้อยมาก จนผลต่างของน้ำหนักไม่สามารถข้ามผ่านเกณฑ์ min_turnover_threshold = 0.01 (1% No-trade band) ได้ พอร์ตจึงกลายสภาพเป็นพอร์ต Buy-and-Hold แบบคงที่ตลอดสัปดาห์

7. การตรวจสอบความถูกต้องทางนิติวิทยาศาสตร์ของระบบ (Forensic System Audit)

จากการตรวจสอบเชิงลึกต่อ Source Code และ Checkpoint Artifacts พบข้อบกพร่องทางสถาปัตยกรรม 3 ประเด็นสำคัญที่นักวิจัยต้องตระหนัก:

7.1 ข้อผิดพลาดการคำนวณผลตอบแทนเงินสด (The Cash-Yield Normalization Bug)

ในโมดูลสำหรับการสร้างข้อมูล คอลัมน์อัตราดอกเบี้ย fed_funds_rate ถูกจัดให้อยู่ในกลุ่ม ALL_FEATURES ซึ่งถูกนำไปปรับมาตรฐานทางสถิติ Z-Score ผ่านฟังก์ชัน apply_scaling():

$$z_{t,\text{FED}} = \frac{\text{FF}_t - \mu_{\text{FED}}^{\text{train}}}{\sigma_{\text{FED}}^{\text{train}}}$$

ทว่าในคลาสสภาพแวดล้อม InstitutionalPortfolioEnv ฟังก์ชัน _build_matrices() กลับดึงค่าที่ผ่านการสเกลแล้วมาคำนวณอัตราผลตอบแทนเงินสดรายวันโดยตรง:

$$y_t^{\text{cash, corrupted}} = \left(1.0 + z_{t,\text{FED}}\right)^{\frac{1}{252}} - 1.0$$

ผลกระทบเชิงสถิติ: $z_{t,\text{FED}}$ มีโอกาสติดลบหรือมีค่าเบี่ยงเบนผิดไปจากอัตราผลตอบแทนดอกเบี้ยจริงตามธรรมชาติอย่างสิ้นเชิง ยิ่งไปกว่านั้น ค่า $\mu_{\text{FED}}^{\text{train}}$ ของแต่ละ Fold มีค่าไม่เท่ากัน (เนื่องจากความยาวของ Train Window ต่างกัน) ส่งผลให้ในวันเดียวกัน พอร์ตแต่ละวิธีกลับได้รับดอกเบี้ยเงินสดไม่เท่ากัน ซึ่งเป็นข้อผิดพลาดร้ายแรงทางบัญชีที่ส่งผลรบกวนฟังก์ชันรางวัลระหว่างการฝึกฝน

7.2 กับดักการบันทึก Checkpoint ก่อนการเรียนรู้ (Premature Checkpoint Selection Trap)

จากการตรวจสอบรายละเอียด Metadata ของไฟล์ best_model.zip ในทั้งสามโมเดล พบข้อมูลที่น่าตกใจดังนี้:

- num_timesteps = 4,000
- _n_updates = 0

สาเหตุทางเทคนิค: พารามิเตอร์การประเมินในโค้ดถูกตั้งไว้ที่ eval_freq = max(500, 2000 // max_cpu) = 500 ต่อ Worker เมื่อทำงานร่วมกับ 8 Parallel Environments (SubprocVecEnv) [5] ทำให้ EvalCallback ถูกกระตุ้นที่ Timestep รวมเท่ากับ $500 \times 8 = 4{,}000$ steps ซึ่งเกิดขึ้น **ก่อนที่ PPO จะสะสมประสบการณ์ครบ Rollout แรกที่ 8,192 steps** ส่งผลให้โมเดลประเมินผลนโยบายแบบสุ่มเริ่มต้น (Random Initialized Weights) และบันทึกไฟล์ทับเป็น best_model.zip โดยที่ยังไม่เคยเกิดการ Update Gradient แม้แต่ครั้งเดียว (_n_updates = 0) ปรากฏการณ์นี้ตอบคำถามได้อย่างชัดเจนว่าเหตุใดในการทดสอบสดโมเดลจึงทำนาย Action สม่ำเสมอและส่งผลให้น้ำหนักลู่เข้าสู่ Equal-Weight 20%

7.3 อคติจากการมองเห็นอนาคตในตัวเปรียบเทียบ (Lookahead Bias in Baseline)

ในฟังก์ชัน run_ablation_baselines() ตัวแปร scalar ของ EqW-VT ถูกคำนวณโดยนำผลตอบแทนของวันปัจจุบัน (portfolio_step_return=raw_ret) ไปอัปเดตความแปรปรวนก่อน แล้วนำตัวคูณที่ได้มาคูณกับผลตอบแทนของวันเดียวกัน ซึ่งถือเป็นการใช้ข้อมูลอนาคตในงวดเวลาเดียวกัน (Lookahead Bias) ทำให้เกณฑ์มาตรฐานดังกล่าวไม่สะท้อนข้อเท็จจริงอย่างแท้จริง

8. อภิปรายผลและแนวปฏิบัติเชิงวิศวกรรม (Discussion & Guidelines)

8.1 การตอบคำถามวิจัย (Synthesis of Research Questions)

- **ตอบ RQ1:** ผลย้อนหลังบนช่วง Common OOS รายงานว่า Sliding Window มี Sharpe Ratio สูงสุด (2.44) อย่างไรก็ดี เมื่อคำนึงถึงข้อผิดพลาดในการคำนวณเงินสดและประเด็น Checkpoint ลำดับดังกล่าวสะท้อนถึงผลลัพธ์ของระบบซอฟต์แวร์รุ่นที่ทดสอบ มากกว่าที่จะเป็นบทสรุปทางเศรษฐศาสตร์ขั้นสมบูรณ์
- **ตอบ RQ2:** ผล Walk-Forward พิสูจน์ให้เห็นว่า Sliding Window มีความยืดหยุ่นต่อสภาวะวิกฤติ (Structural Breaks) สูงกว่า Expanding Window อย่างมีนัยสำคัญ โดยเฉพาะในช่วงการกลับทิศทางของอัตราดอกเบี้ยปี 2022
- **ตอบ RQ3:** การทดสอบเดินหน้าระยะสั้น 5 วัน ให้ผลลัพธ์การเติบโตของพอร์ตที่ใกล้เคียงกัน (~0.85%) แต่ไม่ได้เกิดจากความเหนือกว่าของอัลกอริทึม หากแต่เกิดจาก **Policy Convergence Trap** ที่ทุกโมเดลกลายสภาพเป็น Equal-Weight พอร์ตโฟลิโอ

8.2 ข้อผิดพลาดที่ต้องระวังในการพัฒนาระบบ Financial DRL

1. การแยกสัญญาณบัญชีออกจากสัญญาณการเรียนรู้ (Strict Signal Decoupling): ห้ามนำข้อมูลที่จะถูกใช้ในการคำนวณทางการเงิน (เช่น ดอกเบี้ย, เงินปันผล) ไปรวมไว้ในตาราง Normalization รวมโดยเด็ดขาด

2. การตั้งค่า Callback Synchronization: ในการฝึกแบบ Multiprocessing จะต้องกำหนด eval_freq ให้เป็น

จำนวนเท่าของ n_steps * n_envs เสมอ เพื่อป้องกันไม่ให้เกิดการประเมินผลก่อนสิ้นสุด Rollout แรก

3. การประเมินผลแบบเปิดเผยค่า Audit: ระบบควรตรวจสอบค่า _n_updates ของ Checkpoint ที่โหลดเข้ามาเสมอ หาก _n_updates == 0 ระบบต้องส่งสัญญาณเตือนข้อผิดพลาดทันที

9. บทสรุปและการเปิดเผยข้อมูล (Conclusion & Data Availability)

งานวิจัยนี้ได้สาธิตกระบวนการวิจัยแบบครบวงจร ตั้งแต่การตั้งสมมติฐานทางทฤษฎี การจำลองผลย้อนหลัง จนถึงการต่อท่อส่งคำสั่งซื้อขายจริงในตลาดการเงิน แม้ผลลัพธ์เชิงพรรณนาเดิมจะชี้ว่า Sliding Window มีแนวโน้มปรับตัวได้ดีที่สุดในระยะยาว แต่การตรวจสอบเชิงระบบได้เน้นย้ำความจริงสำคัญของวงการ Machine Learning ทางการเงินว่า "ความถูกต้องของสถาปัตยกรรมบัญชีและการประมวลผลต้องมาก่อนการเฉลิมฉลองผลกำไรของอัลกอริทึมเสมอ"

9.1 ข้อมูลการตรวจสอบย้อนกลับ (Reproducibility & Open Artifacts)

- **Codebase & Experiment Scripts:**
    - Repository 1 (Research & Training): [https://github.com/AungMoonLord/Trading-Algorithm-Seminar-/tree/main/Work11]
    - Repository 2 (Webull Live Trading): [https://github.com/AungMoonLord/Trading-Algorithm-Seminar-/tree/main/Work13]
- **Live Inference Platform:** ดำเนินการผ่าน Webull OpenAPI (Sandbox Global Endpoint: api.sandbox.webull.com) พร้อมระบบแจ้งเตือน Real-Time Telegram Reporting
- Funding & Conflicts of Interest: งานวิจัยนี้ไม่มีผลประโยชน์ทับซ้อนและไม่ได้รับทุนสนับสนุนภายนอก

เอกสารอ้างอิง (References)

[1] X.-Y. Liu, H. Yang, Q. Chen, R. Zhang, L. Yang, B. Xiao, and C. D. Wang, "FinRL: A Deep Reinforcement Learning Library for Automated Stock Trading in Quantitative Finance," *arXiv preprint arXiv:2011.09607*, 2020.

[2] D. H. Bailey and M. López de Prado, "The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting and Non-Normality," *The Journal of Portfolio Management*, vol. 40, no. 5, pp. 94–107, 2014.

[3] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal Policy Optimization Algorithms," *arXiv preprint arXiv:1707.06347*, 2017.

[4] M. López de Prado, *Advances in Financial Machine Learning*. Hoboken, NJ, USA: John Wiley & Sons, 2018.

[5] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, and N. Dormann, "Stable-Baselines3: Reliable Reinforcement Learning Implementations," *Journal of Machine Learning Research*, vol. 22, no. 268, pp. 1–8, 2021.